



UNIVERSIDAD TECNOLÓGICA METROPOLITANA

DESARROLLO Y GESTIÓN DE SOFTWARE

DESARROLLO WEB INTEGRAL

CHUC UC JOEL IVAN

Entregable Semana 1

INTEGRANTES:

Buenfil Yunes Julián Nahim

Lopez Uicab Rossana Sofia

Martinez Rivero Allan Alexis

Sima Moo Jafet de Jesus

8° Cuatrimestre

3° Parcial 8-B

13 de Mayo de 2026

1. INTRODUCCION

El presente informe documenta la implementación base del prototipo Tailo, asistente conversacional de la aplicación móvil SwingTails (veterinarias y productos para mascotas). El objetivo del entregable de la Semana 01 es validar que la arquitectura de inferencia local cumple los criterios técnicos definidos en la rúbrica antes de iniciar la fase de interfaz de usuario.

Se selecciono Ollama como motor de inferencia local debido a su filosofía 'Docker-like', su API compatible con OpenAI (con soporte de streaming nativo) y su bajo costo de configuración sobre hardware de escritorio. El modelo seleccionado es Llama 3.1 8B con cuantización Q4_K_M, ejecutado en GPU NVIDIA RTX 5060.

2. BITACORA DE HARDWARE

2.1. Especificaciones del equipo de pruebas

- Sistema Operativo: Microsoft Windows 11 Home (Build 26200)
- Placa base: MSI MS-7C96 (BIOS Aug-2024)
- CPU: AMD Ryzen 7 5700X - 8 núcleos / 16 hilos - 3.4 GHz base
- GPU: NVIDIA GeForce RTX 5060 - 8 GB VRAM (8151 MiB) - arquitectura Blackwell
- Driver / CUDA: NVIDIA 596.21 / CUDA 13.2 (Compute Capability 12.0)
- RAM: 32 GB
- Almacenamiento: 1 TB

```
PS C:\WINDOWS\system32> nvidia-smi
Wed May 13 09:31:35 2026

+-----+
| NVIDIA-SMI 596.21                  Driver Version: 596.21      CUDA Version: 13.2     |
+-----+-----+
| GPU   Name                               Driver-Model  Bus-Id        Disp.A   Volatile Uncorr. ECC |
| Fan  Temp  Perf              Pwr:Usage/Cap |      1863MiB /    8151MiB | GPU-Util  Compute M. |
|                               Pwr:Usage/Cap |      1863MiB /    8151MiB |          MIG M. |
+-----+-----+
|  0  NVIDIA GeForce RTX 5060       WDDM      00000000:23:00.0  On          N/A |
| 36%   38C   P1              24W /   145W |      1863MiB /    8151MiB |    1%      Default  |
|                               Pwr:Usage/Cap |      1863MiB /    8151MiB |          N/A |
+-----+-----+

Processes:
+-----+
| GPU   GI   CI        PID   Type   Process name                      GPU Memory |
|  ID   ID   ID             |                 |           Usage |
+-----+-----+
|  0    N/A  N/A       1432    C+G    C:\Windows\explorer.exe           N/A |
|  0    N/A  N/A       1656    C+G    C:\Windows\System32\dw...         N/A |
|  0    N/A  N/A       1792    C+G    ...5n1h2txyewy\TextInputHost.exe N/A |
|  0    N/A  N/A       3900    C+G    ...indows\System32\ShellHost.exe  N/A |
|  0    N/A  N/A       6084    C+G    ...xyewy\ShellExperienceHost.exe  N/A |
|  0    N/A  N/A       6808    C+G    ...0.3967.54\msedgeview2.exe     N/A |
|  0    N/A  N/A       8908    C+G    ...2txyewy\CrossDeviceResume.exe  N/A |
|  0    N/A  N/A       9764    C+G    ...IA App\CEF\NVIDIA Overlay.exe  N/A |
+-----+-----+
```

```
PS C:\WINDOWS\system32> systeminfo | Select-String "OS Name", "OS Version", "System Manufacturer",
"System Model", "Processor", "Total Physical
>> Memory"
>> nvidia-smi --query-gpu=name,driver_version,memory.total,compute_cap --format=csv
>> Get-CimInstance Win32_Processor | Select-Object Name, NumberOfCores, NumberOfLogicalProcessors
, MaxClockSpeed

OS Name:                        Microsoft Windows 11 Home
OS Version:                    10.0.26200 N/A Build 26200
OS Build Type:                 Multiprocessor Free
System Manufacturer:          Micro-Star International Co., Ltd.
System Model:                  MS-7C96
Processor(s):                  1 Processor(s) Installed.
BIOS Version:                  American Megatrends International, LLC. 1.I0, 7/26/2024
name, driver_version, memory.total [MiB], compute_cap
NVIDIA GeForce RTX 5060, 596.21, 8151 MiB, 12.0

Name                           : AMD Ryzen 7 5700X 8-Core Processor
NumberOfCores                  : 8
NumberOfLogicalProcessors      : 16
MaxClockSpeed                  : 3401
```

2.2. Justificación del modelo seleccionado

El modelo Llama 3.1 8B con cuantización Q4_K_M ocupa aproximadamente 5.9 GB de VRAM sobre los 8 GB disponibles de la RTX 5060, alcanzando un uso del 88% (por debajo del umbral del 90%). La arquitectura Blackwell con CUDA 13.2 permite ejecutar la inferencia con 93% de carga en GPU, dejando solo un 7% residual de procesamiento en CPU. Este balance produce métricas de TTFT (Time To First Token) de 98 ms y throughput sostenido de 45.27 tokens por segundo, ambos muy por encima de los umbrales mínimos de la rúbrica (500 ms y 15 TPS respectivamente).

El CPU Ryzen 7 5700X (8C/16T) y los 32 GB de RAM aseguran que no existan cuellos de botella en el preprocesamiento del prompt ni en la gestión del KV cache durante sesiones prolongadas.

3. CONFIGURACION DEL ENTORNO


3.1. Motor de inferencia: Ollama

Se instalo Ollama (motor basado en Go y llama.cpp) sobre Windows 11. El servicio queda relacionado por defecto a localhost (127.0.0.1:11434), cumpliendo el criterio de Seguridad de Red de la rúbrica al no exponerse a la red pública.

3.2. Descarga del modelo base

```
ollama pull llama3.1:8b
```

El comando descarga el modelo Llama 3.1 8B en su variante cuantizada Q4_K_M por defecto (4.9 GB en disco).



```
Administrator: Windows PowerShell
0 N/A N/A 11684 C+G ..._cu5n1h2txyewy\SearchHost.exe N/A
0 N/A N/A 11692 C+G ...y\StartMenuExperienceHost.exe N/A
0 N/A N/A 12420 C+G ...1g1gvanyjgm\WhatsApp.Root.exe N/A
0 N/A N/A 13808 C+G ...0_3967_54\msedgeview2.exe N/A
0 N/A N/A 16152 C+G ...1\Programs\Opera GX\opera.exe N/A
0 N/A N/A 16536 C+G ...crosoft OneDrive\OneDrive.exe N/A
0 N/A N/A 16660 C+G ...0_3967_54\msedgeview2.exe N/A
0 N/A N/A 16728 C+G ...yb3d8bbwe\Notepad\Notepad.exe N/A
0 N/A N/A 16836 C+G ...crosoft OneDrive\OneDrive.exe N/A
0 N/A N/A 19288 C+G ...Local\Programs\Warp\warp.exe N/A
0 N/A N/A 19960 C+G ...Release\Common7\IDE\SSMS.exe N/A
0 N/A N/A 22836 C+G ...1\Programs\Opera GX\opera.exe N/A
0 N/A N/A 24548 C ...a1\Programs\Ollama\ollama.exe N/A
0 N/A N/A 25916 C+G ...64_zpdnekdrrrea0\Spotify.exe N/A
0 N/A N/A 27284 C+G ...a1\Programs\cursor\Cursor.exe N/A

PS C:\WINDOWS\system32> ollama pull llama3.1:8b
pulling manifest
pulling 667b0c1932bc: 100% 4.9 GB
pulling 948af2743fc7: 100% 1.5 KB
pulling 0ba8f0e314b4: 100% 12 KB
pulling 56bb8bd477a5: 100% 96 B
pulling 455f34728c9b: 100% 487 B
verifying sha256 digest
writing manifest
success
PS C:\WINDOWS\system32> ollama list
NAME ID SIZE MODIFIED
llama3.1:8b 46e0c10c039e 4.9 GB 24 seconds ago
PS C:\WINDOWS\system32>
```

3.3. Modelfile del asistente Tailo

Se creo un Modelfile que define la identidad, los parámetros de inferencia y el system prompt del asistente. Parámetros principales:

- FROM: llama3.1:8b (modelo base)
- temperature: 0.4 (respuestas consistentes pero naturales)
- top_p: 0.9, top_k: 40 (control de muestreo)
- repeat_penalty: 1.1 (evita bucles repetitivos)
- num_ctx: 8192 (ventana de contexto)
- num_predict: 512 (limite por respuesta)
- SYSTEM: define a Tailo como asistente de SwingTails, 7 casos de uso, 4 limites criticos (no diagnosticar, no recetar, redirigir emergencias, no inventar datos) y estilo cercano-formal en español

3.4. Construcción del modelo personalizado

```
ollama create tailo -f Modelfile
```

```
ollama list
```

```
PS C:\WINDOWS\system32> cd "C:\workCodes\utmCodes\programasCuatri9\desarrolloWeb\entregable-semana-01"
PS C:\workCodes\utmCodes\programasCuatri9\desarrolloWeb\entregable-semana-01> ollama create tailo -f Modelfile
gathering model components
using existing layer sha256:667b0c1932bc6ffc593ed1d03f895bf2dc8dc6df21db3042284a6f4416b06a29
using existing layer sha256:948af2743fc78a328dcb3b0f5a31b3d75f415840fdb699e8b1235978392ecf85
using existing layer sha256:0ba8f0e314b4264dfd19df045cde9d4c394a52474bf92ed6a3de22a4ca31a177
creating new layer sha256:06fd4c5d2a77f7933ca48dca4b7d85456be05b1dc4934a16729cbc188a38c4f7
creating new layer sha256:da1e100557ece325a84236e8eae0f1042711ce92631d535272a0bf1cdf9f90a4
writing manifest
success
PS C:\workCodes\utmCodes\programasCuatri9\desarrolloWeb\entregable-semana-01> ollama list
```

NAME	ID	SIZE	MODIFIED
tailo:latest	cdfe3faeee71	4.9 GB	9 seconds ago
llama3.1:8b	46e0c10c039e	4.9 GB	52 minutes ago

3.5. Validación del comportamiento del asistente

Se validó que Tailo respeta su system prompt mediante un prompt que combina búsqueda de producto y mención de condición médica:

```
ollama run tailo "Hola, busco croquetas para un gato senior con problemas renales."
```

La respuesta confirmó los límites del prompt: el asistente no diagnosticó, sino que redirigió al catálogo de la app, solicitó datos faltantes (tipo de problema renal, edad) y mantuvo el tono cercano-formal definido.

```
PS C:\workCodes\utmCodes\programasCuatri9\desarrolloWeb\entregable-semana-01> ollama run tailo
"Hola, busco croquetas para un gato senior con problemas renales."
Lo siento, pero como asistente virtual no puedo proporcionar diagnósticos médicos ni
recomendar productos específicos sin conocer más detalles sobre la condición renal del
gato y sus necesidades nutricionales actuales.

Puedo ayudarte a encontrar croquetas para gatos senior en nuestro catálogo. ¿Podrías
decirme qué tipo de problemas renales tiene tu mascota (si es diabético, si tiene
insuficiencia renal crónica, etc.) y su edad aproximada? Así puedo sugerirte opciones
adecuadas.

PS C:\workCodes\utmCodes\programasCuatri9\desarrolloWeb\entregable-semana-01> _
```

4. BENCHMARK LOCAL: METRICAS DE RENDIMIENTO

4.1. Procedimiento de medición

Las métricas se obtuvieron ejecutando el modelo en modo verbose con un prompt representativo de uso real del asistente:

```
ollama run llama3.1:8b --verbose "Explica en 3 párrafos qué es la inferencia local de modelos de lenguaje y sus ventajas frente al uso de APIs en la nube."
```

Mientras el modelo generaba la respuesta, en paralelo se ejecutaron los comandos `ollama ps` y `nvidia-smi` para registrar el uso de VRAM y la distribución CPU/GPU.

4.2. Resultados

Distribución de procesamiento (ollama ps):

- Tamaño del modelo en memoria: 5.9 GB
- Procesador: 7% CPU / 93% GPU
- Ventana de contexto activa: 4096 tokens

```
PS C:\WINDOWS\system32> ollama run llama3.1:8b --verbose "Explica en 3 párrafos qué es la inferencia local de modelos de lenguaje y sus ventajas frente al uso de APIs en la nube."
La inferencia local de modelos de lenguaje se refiere a la capacidad de realizar tareas de procesamiento de lenguaje natural (PLN) directamente en el dispositivo de un usuario, sin necesidad de conectarse a una red en línea y enviar datos a servicios en la nube. Esto permite una mayor privacidad y seguridad, ya que los datos no se envían fuera del entorno controlado por el usuario. En lugar de eso, el modelo de lenguaje se almacena en la memoria local del dispositivo y puede procesar solicitudes de texto directamente.

Esta tecnología es especialmente útil para aplicaciones que requieren una alta disponibilidad o velocidad, como servicios de chatbots, asistentes virtuales o aplicaciones de traducción en tiempo real. Además, la inferencia local permite a los desarrolladores ahorrar costos y recursos asociados con la infraestructura de nube y la conectividad. También puede ser más fácil de implementar y mantener que una solución basada en APIs en la nube.

Algunas de las ventajas de la inferencia local frente al uso de APIs en la nube incluyen una mayor privacidad y seguridad, ya que los datos no se envían a un servicio externo. También permite una mejor experiencia para el usuario, con menores tiempos de respuesta y mayor disponibilidad. Además, la inferencia local puede ser más escalable y personalizable que las APIs en la nube, ya que los desarrolladores pueden adaptar fácilmente los modelos a las necesidades específicas de su aplicación o servicio.

total duration:      54.980497s
load duration:      46.5099568s
prompt eval count:   45 token(s)
prompt eval duration: 98.7515ms
prompt eval rate:    455.69 tokens/s
eval count:          330 token(s)
eval duration:       7.2900676s
eval rate:           45.27 tokens/s
```


Uso de VRAM (nvidia-smi durante inferencia):

- VRAM usada: 7215 MiB de 8151 MiB (88%, bajo el umbral del 90% de la rúbrica)
- Temperatura GPU: 40 C
- Consumo: 24 W de 145 W

```
Administrator: Windows PowerShell
PS C:\WINDOWS\system32> ollama ps
NAME ID SIZE PROCESSOR CONTEXT UNTIL
llama3.1:8b 46e0c10c039e 5.9 GB 7%/93% CPU/GPU 4096 4 minutes from now
PS C:\WINDOWS\system32> nvidia-smi
Wed May 13 10:06:35 2026

+-----+
| NVIDIA-SMI 596.21 | Driver Version: 596.21 | CUDA Version: 12.2 |
+-----+
| GPU Name | Driver-Model | Bus-Id | Disp.A | Volatile Uncorr. ECC |
| Fan Temp | Perf | Pwr:Usage/Cap | Memory-Usage | GPU-Util Compute M. |
|-----+-----+-----+-----+-----+
| 0 NVIDIA GeForce RTX 5060 | WDDM | 00000000:23:00.0 On | 7215MiB / 8151MiB | 0% Default |
| 36% 40C P1 | 24W / 145W | | | | |
+-----+-----+-----+-----+-----+

Processes:
+-----+
| GPU | GI | CI | PID | Type | Process name | GPU Memory |
| ID | ID | ID | | | | Usage |
+-----+
| 0 | N/A | N/A | 1432 | C+G | C:\Windows\explorer.exe | N/A |
| 0 | N/A | N/A | 1656 | C+G | C:\Windows\System32\dw... | N/A |
| 0 | N/A | N/A | 1792 | C+G | ...5n1h2txyewy\TextIn... | N/A |
| 0 | N/A | N/A | 3900 | C+G | ...indows\System32\Sh... | N/A |
| 0 | N/A | N/A | 6084 | C+G | ...xyewy\ShellExperi... | N/A |
| 0 | N/A | N/A | 6888 | C+G | ...0.3967.54\msedgeb... | N/A |
+-----+
```

Métricas de rendimiento (ollama --verbose):

- load duration: 46.51 s (carga inicial del modelo a VRAM, evento único)
- prompt eval count: 45 tokens
- prompt eval duration: 98.75 ms - equivalente al TTFT
- prompt eval rate: 455.69 tokens/s
- eval count: 330 tokens generados
- eval duration: 7.29 s
- eval rate: 45.27 tokens/s - throughput sostenido

4.3. Comparativa contra umbrales de la rúbrica

Resumen del cumplimiento de los criterios técnicos:

- TTFT - Medido: 98.75 ms / Umbral: menos de 500 ms / Estado: APROBADO (5x mejor)
- Throughput - Medido: 45.27 TPS / Umbral: más de 15 TPS / Estado: APROBADO (3x mejor)
- VRAM - Medido: 88% / Umbral: menos de 90% / Estado: APROBADO
- Cuantización - Medido: Q4_K_M / Umbral: Q4_K_M o Q8_0 / Estado: APROBADO

5. PRUEBA DE ENDPOINT CON STREAMING

Ollama expone un endpoint compatible con la API de OpenAI en la ruta `/v1/chat/completions`. Se realizo una prueba de streaming para validar el criterio 'Estandar de API' de la rúbrica.

5.1. Solicitud


```
curl.exe http://localhost:11434/v1/chat/completions -H "Content-Type: application/json" -d '{"model": "tailor", "messages": [{"role": "user", "content": "Recomiendame 3 juguetes para un cachorro labrador de 2 meses."}], "stream": true}'
```

5.2. Respuesta

La respuesta llego como una secuencia de chunks Server-Sent Events (SSE), cada uno con la estructura estándar de OpenAI:

```
data: {"id":"chatcmpl-24","object":"chat.completion.chunk","created":1778689844,"model":"tailor","system_fingerprint":"fp_ollama","choices":[{"index":0,"delta":{"role":"assistant","content":"Aquí"},"finish_reason":null}]}
```

Se observaron múltiples chunks consecutivos hasta el cierre con finish_reason: 'stop' seguido de data: [DONE].



```
Administrator: Windows PowerShell
PS C:\workCodes\utmCodes\programasCuatri9\desarrolloWeb\entregable-semana-01> curl.exe http://localhost:11434/v1/chat/completions -H "Content-Type: application/json" -d '{"model": "tailor", "messages": [{"role": "user", "content": "Recomiendame 3 juguetes para un cachorro labrador de 2 meses."}], "stream": true}'

data: {"id": "chatcmpl-24", "object": "chat.completion.chunk", "created": 1778689844, "model": "tailor", "system_fingerprint": "fp_ollama", "choices": [{"index": 0, "delta": {"role": "assistant", "content": "Aqu\u00ed", "finish_reason": null}}]}

data: {"id": "chatcmpl-24", "object": "chat.completion.chunk", "created": 1778689844, "model": "tailor", "system_fingerprint": "fp_ollama", "choices": [{"index": 0, "delta": {"role": "assistant", "content": "i", "finish_reason": null}}]}

data: {"id": "chatcmpl-24", "object": "chat.completion.chunk", "created": 1778689844, "model": "tailor", "system_fingerprint": "fp_ollama", "choices": [{"index": 0, "delta": {"role": "assistant", "content": " tienes", "finish_reason": null}}]}

data: {"id": "chatcmpl-24", "object": "chat.completion.chunk", "created": 1778689844, "model": "tailor", "system_fingerprint": "fp_ollama", "choices": [{"index": 0, "delta": {"role": "assistant", "content": " tres", "finish_reason": null}}]}

data: {"id": "chatcmpl-24", "object": "chat.completion.chunk", "created": 1778689844, "model": "tailor", "system_fingerprint": "fp_ollama", "choices": [{"index": 0, "delta": {"role": "assistant", "content": " opciones", "finish_reason": null}}]}

data: {"id": "chatcmpl-24", "object": "chat.completion.chunk", "created": 1778689844, "model": "tailor", "system_fingerprint": "fp_ollama", "choices": [{"index": 0, "delta": {"role": "assistant", "content": " para", "finish_reason": null}}]}

data: {"id": "chatcmpl-24", "object": "chat.completion.chunk", "created": 1778689844, "model": "tailor", "system_fingerprint": "fp_ollama", "choices": [{"index": 0, "delta": {"role": "assistant", "content": " ", "finish_reason": null}}]}

data: {"id": "chatcmpl-24", "object": "chat.completion.chunk", "created": 1778689852, "model": "tailor", "system_fingerprint": "fp_ollama", "choices": [{"index": 0, "delta": {"role": "assistant", "content": " h\u00e1", "finish_reason": null}}]}

data: {"id": "chatcmpl-24", "object": "chat.completion.chunk", "created": 1778689852, "model": "tailor", "system_fingerprint": "fp_ollama", "choices": [{"index": 0, "delta": {"role": "assistant", "content": " z", "finish_reason": null}}]}

data: {"id": "chatcmpl-24", "object": "chat.completion.chunk", "created": 1778689852, "model": "tailor", "system_fingerprint": "fp_ollama", "choices": [{"index": 0, "delta": {"role": "assistant", "content": " ma", "finish_reason": null}}]}

data: {"id": "chatcmpl-24", "object": "chat.completion.chunk", "created": 1778689852, "model": "tailor", "system_fingerprint": "fp_ollama", "choices": [{"index": 0, "delta": {"role": "assistant", "content": " elo", "finish_reason": null}}]}

data: {"id": "chatcmpl-24", "object": "chat.completion.chunk", "created": 1778689852, "model": "tailor", "system_fingerprint": "fp_ollama", "choices": [{"index": 0, "delta": {"role": "assistant", "content": " saber", "finish_reason": null}}]}

data: {"id": "chatcmpl-24", "object": "chat.completion.chunk", "created": 1778689852, "model": "tailor", "system_fingerprint": "fp_ollama", "choices": [{"index": 0, "delta": {"role": "assistant", "content": " .", "finish_reason": null}}]}

data: {"id": "chatcmpl-24", "object": "chat.completion.chunk", "created": 1778689852, "model": "tailor", "system_fingerprint": "fp_ollama", "choices": [{"index": 0, "delta": {"role": "assistant", "content": " ", "finish_reason": "stop"}}]}

data: [DONE]
```

5.3. Validaci3n

- Endpoint compatible con OpenAI: /v1/chat/completions - confirmado
- Streaming activo: chunks SSE con delta.content - confirmado
- Modelo identificado correctamente: 'model': 'tailor' - confirmado
- Servicio en localhost (127.0.0.1:11434) sin exposici3n p3blica - confirmado

6. CONCLUSIONES

La implementación base de Tailo cumple los seis criterios técnicos de la rúbrica con margen significativo. El hardware seleccionado (RTX 5060 + Ryzen 7 5700X + 32 GB RAM) demostró ser apto para ejecutar Llama 3.1 8B Q4_K_M en GPU con rendimiento muy superior a los umbrales mínimos.

El system prompt del Modelfile fue validado funcionalmente: el asistente respeta los límites críticos (no diagnostica, no receta, redirige emergencias) y mantiene el tono cercano-formal definido para SwingTails. El endpoint OpenAI-compatible con streaming habilita la integración directa desde la aplicación móvil sin necesidad de un gateway adicional.

Con esta base validada, el prototipo está listo para avanzar a la fase de interfaz de usuario.