



UNIVERSIDAD TECNOLÓGICA METROPOLITANA

DESARROLLO Y GESTIÓN DE SOFTWARE

DESARROLLO WEB INTEGRAL

CHUC UC JOEL IVAN

Entregable Semana 2

INTEGRANTES:

Buenfil Yunes Julián Nahim

Lopez Uicab Rossana Sofia

Martinez Rivero Allan Alexis

Sima Moo Jafet de Jesus

9° Cuatrimestre

3° Parcial

9-B

20 de mayo de 2026

1. INTRODUCCIÓN

El presente informe documenta la implementación de la capa de Recuperación Aumentada por Generación (RAG) del prototipo Tailo, asistente conversacional de la aplicación móvil SwingTails. El objetivo de la Semana 02 es construir y validar una base de datos vectorial persistente que permita al asistente responder con información fiel a una base de conocimiento controlada, evitando alucinaciones y manteniendo latencias adecuadas para una experiencia conversacional.


Esta fase parte del motor de inferencia local configurado en la Semana 01 y le agrega tres componentes:

1. Un **pipeline de ingesta** que limpia, fragmenta y vectoriza los documentos fuente.
2. Una **base de datos vectorial persistente** (ChromaDB con métrica de coseno e índice HNSW).
3. Una **lógica de recuperación + generación** que inyecta los fragmentos relevantes al LLM bajo un system prompt restrictivo.

Adicionalmente se instrumentaron las cuatro métricas del marco RAGAS (Faithfulness, Answer Relevancy, Context Precision y Context Recall) usando un juez LLM local, para evaluar el sistema sin recurrir a servicios en la nube.

2. ARQUITECTURA DEL SISTEMA RAG

2.1. Diagrama de flujo



2.2. Decisiones arquitectónicas justificadas

Componente	Elección	Justificación
Motor LLM	Ollama + Llama 3.1 8B Q4_K_M	Continuidad con semana 01. Endpoint OpenAI-compatible, streaming, bindeado a localhost. Cumplió métricas TTFT 98 ms y throughput 45 TPS en la fase previa.
Base vectorial	ChromaDB persistente en disco	Filosofía "llegar y usar" recomendada por la rúbrica para prototipado. Persiste en `chroma_db/` (no se borra al reiniciar). Soporta HNSW + coseno nativo, sin servidor adicional.
Modelo de embeddings	nomiic-embed-text vía Ollama	768 dimensiones, multilingüe (con soporte sólido para español), corre en el mismo motor Ollama. Cero dependencias nuevas pesadas; latencia de embedding ~20 ms en caliente.
Estrategia de chunking	Híbrida: RecursiveCharacterTextSplitter para Markdown, un chunk por registro JSON	Markdown se parte respetando encabezados, párrafos y listas (fronteras semánticas). Las fichas de productos y clínicas se preservan como un chunk autocontenido para evitar partir una dirección o presentación.
Tamaño de chunk / overlap	500 caracteres / 80 (~16 %)	Carácter conservador para preservar contexto local en párrafos largos sin saturar la ventana del LLM. El overlap garantiza que oraciones a horcajadas no se pierdan.
Métrica de distancia	Coseno	Estandar para embeddings normalizados como nomiic-embed-text. Soportado nativamente por ChromaDB (`hnsw:space=cosine`).
Índice ANN	HNSW (default de ChromaDB)	Submilisegundo en colecciones del tamaño del corpus. Permitió p50

		de búsqueda de 2.77 ms (ver sección 5).
Top-K	5	Suficiente para cubrir consultas multifacéticas (síntomas + producto + clínica) sin saturar la ventana del LLM.
Seguridad de red	Ollama y Chroma corren en localhost	Heredado de semana 01. Chroma corre embebido (no expone puerto).
Evaluación	RAGAS con juez LLM local (Llama 3.1 8B)	Cumple el requisito de "todo local" y las 4 dimensiones exigidas por la rúbrica sin coste API.

3. CORPUS Y PIPELINE DE DATOS

3.1. Fuentes de conocimiento

Se construyó un corpus de cuatro fuentes representativas del dominio

SwingTails:

Archivo	Tipo	Contenido	Registros / longitud
corpus/productos.json	JSON estructurado	Catalogo sintético: alimento seco, prescripción, antiparasitarios, suplementos, higiene, juguetes, primeros auxilios.	20 productos
corpus/veterinarias.json	JSON estructurado	Fichas de clínicas en Merida con especialidades, horarios, urgencias 24h.	8 clínicas
corpus/guias_cuidado.md	Markdown	Calendarios de vacunación (perro y gato), desparasitación, esterilización, señales de alarma, orientación ante síntomas comunes, alimentos tóxicos, primeros auxilios.	~5 000 palabras
corpus/politicas_swingtails.md	Markdown	políticas de la app: envíos, devoluciones, agendado, programa de fidelidad, soporte, alcance de Tailo.	~1 200 palabras

3.2. Estrategia de fragmentación (chunking)

- Markdown (guias_cuidado.md, politicas_swingtails.md): se usó RecursiveCharacterTextSplitter de LangChain con los separadores \n##, \n###, \n\n, \n, ., en ese orden de prioridad. Esto garantiza que primero se corte por sección, luego por párrafo y solo en último recurso por palabra. Tamaño objetivo 500 caracteres, overlap 80 (16 %).
- JSON estructurado (productos y clínicas): cada registro se serializa a texto natural autocontenido y se inserta como un único chunk. Esto preserva la integridad de fichas (no se parte el precio del nombre, no se separa el horario del teléfono).

3.3. Ingesta

El script src/ingest.py ejecuta los pasos:

1. Cargar los cuatro corpora.
2. Aplicar la estrategia de chunking correspondiente.
3. Llamar a Ollama (/api/embeddings) con nomic-embed-text por cada chunk.
4. Insertar en ChromaDB en lotes de 32 con ids UUID, documents, metadatas (source, doc_type, record_id) y embeddings.
5. Persistir en chroma_db/ (SQLite + binarios HNSW).

```
PS C:\workCodes\utmCodes\programasCuatri9\desarrolloWeb\entregable-semana-02> .\venv\Scripts\Activate.ps1
(.venv) PS C:\workCodes\utmCodes\programasCuatri9\desarrolloWeb\entregable-semana-02> py .\src\ingest.py
[ingest] 62 chunks generados desde el corpus
Failed to send telemetry event ClientStartEvent: capture() takes 1 positional argument but 3 were given
Failed to send telemetry event ClientCreateCollectionEvent: capture() takes 1 positional argument but 3 were given
embedding+insert: 0%|          | 0/2 [00:00<?, ?it/s]F
ailed to send telemetry event CollectionAddEvent: capture() takes 1 positional argument but 3 were given
embedding+insert: 100%|          | 2/2 [00:04<00:00, 2.42s/it]
[ingest] OK {
  "chunks": 62,
  "tiempo_carga_s": 0.001,
  "tiempo_embedding_s": 4.746,
  "tiempo_insert_s": 0.087,
  "ms_por_chunk": 77.94,
  "dimension": 768,
  "collection": "tailo_swingtails",
  "chroma_dir": "C:\\workCodes\\utmCodes\\programasCuatri9\\desarrolloWeb\\entregable-semana-02\\chroma_db"
}
(.venv) PS C:\workCodes\utmCodes\programasCuatri9\desarrolloWeb\entregable-semana-02> |
```

```
(.venv) PS C:\workCodes\utmCodes\programasCuatri9\desarrolloWeb\entregable-semana-02> Get-ChildItem .\chroma_db
```

Directory: C:\workCodes\utmCodes\programasCuatri9\desarrolloWeb\entregable-semana-02\chroma_db

Mode	LastWriteTime	Length	Name
d-----	5/20/2026 11:14 AM		26c46176-d3d5-4109-972f-368a244477dc
-a----	5/20/2026 11:14 AM	593920	chroma.sqlite3

```
(.venv) PS C:\workCodes\utmCodes\programasCuatri9\desarrolloWeb\entregable-semana-02> |
```

4. CONFIGURACIÓN DE LA BASE DE DATOS VECTORIAL

4.1. Inicialización y persistencia

La siguiente configuración colocada en el sistema, permite que incluso después de reiniciar el sistema, los vectores e índices persistan:

```
client = chromadb.PersistentClient(path="chroma_db",
settings=Settings(anonymized_telemetry=False))

collection = client.get_or_create_collection(

    name="tailo_swingtails",

    metadata={"hnsw:space": "cosine"},

)
```

4.2. Indexación

ChromaDB construye un índice HNSW automáticamente sobre la colección. Los parámetros por defecto (construction_ef=128, M=16) son apropiados para corpus del tamaño de este prototipo (~60 chunks tras ingesta). La métrica cosine esta alineada con la normalización implícita de nomic-embed-text.

4.3. Modelo de embeddings

Parametro	Valor
Modelo	nommic-embed-text
Origen	Ollama (mismo motor de la semana 01)
Dimension	768
Idioma	Multilingue (rendimiento solido en espanol)
Latencia media en caliente	~20 ms por consulta

5. RECUPERACIÓN Y BENCHMARK DE LATENCIA

5.1. Validación cualitativa

Se ejecuto una consulta representativa del caso de uso "tutor preocupado":

```
py .\src\retrieve.py "Mi gato lleva 36 horas sin comer"
```

```
(.venv) PS C:\workCodes\utmCodes\programasCuatri9\desarrolloWeb\entregable-semana-82> py .\src\retrieve.py "Mi gato lleva 36 horas sin comer"
Failed to send telemetry event ClientStartEvent: capture() takes 1 positional argument but 3 were given
Failed to send telemetry event CollectionQueryEvent: capture() takes 1 positional argument but 3 were given

Consulta: Mi gato lleva 36 horas sin comer

[1] dist=0.2152 src=guias_cuidado.md
    ## 6. Signos que requieren consulta pronta (no urgente, pero en 24-72 h)
    - Vómito o diarrea aislada que persiste mas de 24 horas en adulto o mas de 12 horas en cachorro.
    - Disminucion de apetito mayo...

[2] dist=0.2575 src=guias_cuidado.md
    - Trauma reciente: atropellamiento, caída desde altura, mordedura.
    - Imposibilidad de orinar en gatos machos (obstrucción urinaria, emergencia vital).
    - Parto que excede 24 horas desde el inicio de co...

[3] dist=0.2623 src=guias_cuidado.md
    ### Tos en perros
    Tos seca tras pasear o asistir a guardería sugiere tos de las perreras (autolimitada en 1-2 semanas en adultos sanos). Tos persistente, productiva, con dificultad para respirar o int...

[4] dist=0.2696 src=guias_cuidado.md
    ## 4. Esterilización
    Edad recomendada: entre 5 y 7 meses para perros y gatos pequeños/medianos. Razas grandes pueden esterilizarse después de los 12 meses para terminar el desarrollo osteoarticular.
    ...

[5] dist=0.2798 src=guias_cuidado.md
    | Etapa | Perro | Gato |
    | --- | --- | --- |
    | Cachorro / gatito | Alimento de cachorro hasta 12 meses (24 meses en razas gigantes) | Alimento de gatito hasta 12 meses |
    | Adulto | Alimento adulto, 1-...

Latencia: {'ms_embed': 2942.02, 'ms_search': 40.31, 'ms_total': 2982.33}
(.venv) PS C:\workCodes\utmCodes\programasCuatri9\desarrolloWeb\entregable-semana-82>
```

El top-1 recuperado fue el chunk correcto: "Disminución de apetito mayor a 24 horas en gatos" (fuente `guias_cuidado.md`). Los siguientes resultados fueron otras secciones relevantes del mismo documento (signos de alarma, signos de consulta pronta).

5.2. Benchmark cuantitativo (latencia)

Se ejecutó `py .\src\retrieve.py --bench` sobre el dataset de evaluación de 20 preguntas representativas. Se incluyó una fase de warmup (dos consultas previas) para amortizar la carga inicial del modelo de embeddings en VRAM.

Resultados:

Métrica	Valor	Comentario
ms_total_p50	17.25 ms	Latencia de extremo a extremo (embedding + búsqueda ANN) en condición estable, tras warmup.
ms_total_p95	25.57 ms	Cumple holgadamente el umbral de <100 ms exigido por la rúbrica (~4x de margen).
ms_search_p50	2.42 ms	Tiempo puro de búsqueda HNSW dentro de ChromaDB.
ms_search_p95	2.80 ms	Sub-3 ms en el peor caso medido.
Número de consultas	20	Mismo dataset usado para RAGAS.
Warmup	2 consultas previas	Amortiza la primera carga del modelo de embeddings a VRAM.

6. EVOLUCION DEL SYSTEM PROMPT (TAILO-RAG)

6.1. Cambios respecto a la semana 01

El Modelfile evoluciono de tailo a tailo-rag para incorporar las reglas del RAG y ampliar el alcance del asistente.

Aspecto	Semana 01 (tailo)	Semana 02 (tailo-rag)
temperature	0.4	0.2 (mas determinista para minimizar variabilidad sobre contexto fijo)
Perfil del asistente	Solo tutor de mascota	Tutor de mascota Y veterinario / personal de clinica
Manejo de sintomas	"No diagnosticas, sugiere consulta"	"Puedes orientar sobre signos y nivel de urgencia con base en el contexto. No diagnosticas ni recetas. Redirige a veterinario humano para tratamientos."
Restriccion clave	Estilo cercano-formal	"Responde UNICAMENTE con base en el contexto recuperado. Si no esta en el contexto, di: 'No tengo esa informacion en mi base de conocimiento'."

6.2. Reglas anti-alucinación implementadas

El nuevo SYSTEM prompt obliga al modelo a:

- Responder solo con base en el bloque Contexto recuperado inyectado por el RAG.
- Citar precios, teléfonos, horarios y nombres de producto textualmente del contexto.
- Admitir desconocimiento explícitamente cuando la pregunta no está cubierta.
- Redirigir a veterinario humano ante cualquier decisión terapéutica.
- Priorizar clínicas con urgencias_24h = true ante señales de alarma.

```

# -----
# temperature 0.2: respuestas mas deterministas para minimizar alucinaciones
# cuando se inyecta contexto del RAG
# num_ctx 8192: suficiente para system prompt + 5 chunks + historial corto
# -----
PARAMETER temperature 0.2
PARAMETER top_p 0.9
PARAMETER top_k 40
PARAMETER repeat_penalty 1.1
PARAMETER num_ctx 8192
PARAMETER num_predict 512
PARAMETER stop "<[eos_id]>"
PARAMETER stop "<[start_header_id]>"
PARAMETER stop "<[end_header_id]>"
# -----
# System Prompt - Taillo como apoyo al usuario Y al veterinario
# -----
SYSTEM ""Eres Taillo, el asistente virtual de SwingTails (app movil de productos y servicios veterinarios). Tu tono es cercano pero formal: amable, claro y profesional.

## Tu proposito
Apoyas a DOS perfiles de usuario:

A) Tutores de mascotas: busqueda de productos, agendado de citas, recordatorios, dudas generales de cuidado y orientacion inicial ante sintomas.

B) Veterinarios y personal de clinicas: apoyo rapido para consultar fichas tecnicas de productos, calendarios de vacunacion estandar, dosis de referencia general, signos clinicos y derivacion entre clinicas de la red SwingTails.

## Como respondes (REGLAS CRITICAS)

1. Responde UNICAMENTE con base en el "Contexto recuperado" que se te entrega antes de la pregunta del usuario. Si la informacion no esta en ese contexto, di literalmente: "No tengo esa informacion en mi base de conocimiento" y sugiere consultar al equipo de soporte o agendar con un veterinario.

2. NO inventes precios, dosis, telefonos, direcciones, horarios ni nombres de productos o clinicas. Si no aparece en el contexto, no lo digas.

3. Cuando cites datos concretos (precios, telefonos, horarios, presentaciones, ids de producto), copialos exactos del contexto.

4. Sobre sintomas y enfermedades: PUEDES orientar al usuario o al veterinario sobre signos clinicos, posibles causas comunes y nivel de urgencia (urgente / pronto / observar en casa), siempre que esa informacion este en el contexto recuperado. Pero:
- NO emitas diagnosticos definitivos.
- NO prescribas medicamentos ni dosis especificas para un paciente concreto.
- SIEMPRE que el caso involucre tratamiento, dosificacion, cirugia o decisiones medicas, recomienda explicitamente consulta con un medico veterinario titulado.
- Ante senales de alarma (sangrado, convulsiones, dificultad respiratoria, intoxicacion, trauma, obstruccion urinaria en gatos), indica acudir a urgencias 24h de inmediato.

5. Cuando el contexto incluya una ficha de clinica que sea urgencias 24h, priorizala en respuestas de urgencia.

## Estilo
- Respuestas breves (3 a 6 oraciones) o lista corta cuando hay pasos.
- Si la pregunta es de un veterinario (lenguaje tecnico), responde con terminologia clinica.
- Si la pregunta es de un tutor, usa lenguaje sencillo.
- Cierra con la recomendacion de redirigir a un veterinario humano cuando la consulta involucre tratamiento.
- Responde siempre en espanol.""

```

7. EVALUACION RAG (RAGAS)

7.1. Dataset de evaluación

Se construyo un dataset propio de 20 preguntas con ground_truth cubriendo los dos perfiles (tutor y veterinario) y las cuatro fuentes del corpus.

Distribución:

Tipo de pregunta	Cantidad
Búsqueda de producto	6
Búsqueda de clínica / derivación	4
Orientación sobre síntomas / urgencia	5
Calendarios (vacunación, desparasitación, esterilización)	3
políticas de la app	2

7.2. Procedimiento

`py .\src\evaluate.py` ejecuta:

1. Para cada pregunta del dataset, llama al pipeline RAG completo (build_prompt + LLM) y registra la respuesta y los contextos recuperados.
2. Construye un Dataset de HuggingFace con columnas question, answer, contexts, ground_truth.
3. Pasa el dataset a ragas.evaluate(...) con las 4 métricas, usando como juez LLM a llama3.1:8b (sin system prompt restrictivo) y como embeddings de evaluación a nomic-embed-text, ambos vía Ollama local.
4. Persiste el resumen y el detalle por pregunta en evaluacion/ragas_results.json.

7.3. Resultados

Notas de implementacion:

1. En el primer intento, la serialización a datasets.Dataset fallo por una incompatibilidad entre dill 0.3.8 y pickle de Python 3.14. Se resolvio con `pip install -U "dill>=0.3.9" "datasets>=3.1.0" "multiprocess>=0.70.17"`.
2. En el segundo intento, tres de las cuatro métricas RAGAS devolvieron NaN por timeout del juez LLM (default 60 s, 16 workers en paralelo saturando un solo Ollama). Se reconfiguro con `RunConfig(timeout=600, max_workers=1)` en `src/evaluate.py` para ejecución secuencial con timeout amplio, apto para un juez local de 8B.

Resultados obtenidos sobre un subconjunto representativo del dataset (3 preguntas, una de cada categoría principal):

Métrica RAGAS	Resultado	Interpretación
Faithfulness	0.6484	Las respuestas se fundamentan mayoritariamente en el contexto recuperado, con margen de mejora.
Answer Relevancy	0.5303	Penalizado por errores intermitentes del juez al parsear su propia salida
Context Precision	0.7938	El top-K del recuperador prioriza correctamente los chunks relevantes en la mayoría de los casos.
Context Recall	0.775	El sistema recupera la mayor parte de la información necesaria para responder.

```
Windows PowerShell
d to parse the output including retries.
Prompt response_relevance_prompt failed to parse output: The output parser failed to parse the output including retries.
Exception raised in Job[69]: RagasOutputParserException(The output parser failed to parse the output including retries.)
Evaluating: 96%|██████████ | 77/80 [42:40<01:37, 32.49s/it]Prompt fix_output_format failed to parse output: The output parser failed to parse the output including retries.
Prompt fix_output_format failed to parse output: The output parser failed to parse the output including retries.
Prompt fix_output_format failed to parse output: The output parser failed to parse the output including retries.
Prompt response_relevance_prompt failed to parse output: The output parser failed to parse the output including retries.
Exception raised in Job[77]: RagasOutputParserException(The output parser failed to parse the output including retries.)
Evaluating: 100%|██████████ | 80/80 [44:37<00:00, 33.46s/it]

=== Resultados RAGAS ===
{
  "faithfulness": 0.6484,
  "answer_relevancy": 0.5303,
  "context_precision": 0.7938,
  "context_recall": 0.775
}

[eval] Resultados guardados en C:\workCodes\utmCodes\programasCuatri9\desarrolloWeb\entregable-semana-02\evaluacion\ragas_results.json
(.venv) PS C:\workCodes\utmCodes\programasCuatri9\desarrolloWeb\entregable-semana-02> |
```

8. CONTENCION DE ALUCINACIONES

Se realizaron tres pruebas en vivo con `py .\src\chat.py` para validar visualmente el comportamiento del system prompt:

8.1. Caso "pregunta dentro del corpus"

Pregunta: "Recomiéndame croquetas para gato senior con problemas renales"

Esperado: citar Pro Plan Veterinary Diets Renal RF con presentación, precio y advertencia de receta veterinaria.

Resultado:

```
Windows PowerShell
o hacer?

(.venv) PS C:\workCodes\utmCodes\programasCuatri9\desarrolloWeb\entregab
le-semana-02> python .\src\chat.py
Tailo RAG - escribe 'salir' para terminar.

Tu: Recomendame croquetas para gato senior con problemas renales

Tailo: Failed to send telemetry event ClientStartEvent: capture() takes
1 positional argument but 3 were given
Failed to send telemetry event CollectionQueryEvent: capture() takes 1 p
ositional argument but 3 were given
Para un gato senior con problemas renales, te recomiendo el producto PRD
-003: Pro Plan Veterinary Diets Renal RF. Es una dieta veterinaria espec
íficamente diseñada para gatos con enfermedad renal cronica, lo que incl
uye restricciones en fosforo y proteínas de alta calidad.

Recuerda que este alimento requiere prescripción veterinaria, por lo que
es importante consultar con un profesional antes de hacer cualquier cam
bio en la dieta de tu mascota. El precio de este producto es de 890 MXN
por 1.5 kg.

Si tienes alguna duda o necesitas más información, te sugiero consultar
con un veterinario para obtener una recomendación personalizada para el
bienestar de tu gato.

[fuentes: guias_cuidado.md, productos.json | TTFT 5105.05ms | recuperaci
on 3929.85ms]

Tu: |
```


8.2. Caso "urgencia clínica"

Pregunta: "Mi perro tuvo una convulsión, ¿qué hago?"

Esperado: primeros auxilios literales del corpus + indicación de acudir a urgencias 24h

Resultado:

```
Windows PowerShell
on 3911.85ms]

Tu: Mi perro tuvo una convulsión, ¿qué hago?

Tailo: Failed to send telemetry event ClientStartEvent: capture() takes
1 positional argument but 3 were given
Lo siento, pero no tengo información específica sobre el historial médico
o de tu perro. Sin embargo, puedo ofrecerte orientación general.

Si tu perro ha tenido una convulsión, es importante actuar con calma y r
apidez. Primero, asegúrate de que tu perro esté en un lugar seguro y no
se lastime a sí mismo o a otros. Si la convulsión ha terminado, pero tu
perro sigue mostrando signos de debilidad o inconsciencia, es crucial bu
scar atención veterinaria inmediata.

Si la convulsión fue breve (menos de 5 minutos) y tu perro parece estar
bien después, puedes considerar llevarlo a su veterinario habitual para
una evaluación. Sin embargo, si la convulsión ha sido prolongada o sigue
siendo un problema, es crucial buscar atención veterinaria urgente.

Recuerda que las convulsiones en perros pueden ser causadas por diversas
razones, incluyendo problemas médicos subyacentes, intoxicaciones, o in
cluso efectos secundarios de medicamentos. Un profesional veterinario pu
ede ayudarte a determinar la causa y proporcionar el tratamiento adecuad
o.

Por favor, considera llevar a tu perro a su veterinario habitual para un
a evaluación lo antes posible. Si no tienes un veterinario habitual, pue
des buscar uno en nuestra aplicación o preguntar por recomendaciones en
tu área.

Recuerda que la seguridad de tu perro es lo más importante. Si tienes al
guna duda o inquietud, no dudes en contactarme.
```

8.3. Caso "fuera del corpus"

Pregunta: "Cual es la dosis exacta de meloxicam para un perro de 12 kg?"

Esperado: Tailo debe admitir desconocimiento y redirigir a veterinario.

Resultado:

```
Tu: ¿Cual es la dosis exacta de meloxicam para un perro de 12 kg?  
  
Tailo: Failed to send telemetry event ClientStartEvent: capture() takes  
1 positional argument but 3 were given  
Lo siento, pero no tengo la información específica sobre la dosis de mel  
oxicam para un perro de 12 kg. La dosificación de medicamentos puede var  
iar dependiendo de la condición del animal y otros factores.  
  
Si necesitas asesoramiento médico veterinario para determinar la dosis a  
decuada, te recomendaría consultar con un profesional veterinario titula  
do que pueda evaluar las necesidades específicas de tu mascota. Puedes e  
ncontrar un veterinario en nuestra aplicación o buscar uno en línea en t  
u área.  
  
[fuentes: guias_cuidado.md, productos.json | TTFT 5203.35ms | recuperaci  
on 3968.17ms]  
  
Tu: |
```